

Università degli Studi di Catania

Dipartimento di Matematica e Informatica

Corso di Deep Learning: Advanced Models and
Methods

Relazione Progetto

Knowledge Distillation for Mobile Action Recognition

Autore: Daniele Barbagallo

Matricola: 1000015334

Docente: Prof. Antonino Furnari

Anno Accademico 2025/2026

Indice

1	Introduzione	3
1.1	Obiettivi del Progetto	3
1.2	Organizzazione della Relazione	4
2	Background Teorico	5
2.1	Knowledge Distillation	5
2.1.1	Formulazione Matematica	5
2.1.2	Ruolo della Temperatura	5
2.2	Attention Transfer	6
2.2.1	AT per Immagini 2D	6
2.2.2	Estensione al Video 3D: Attenzione Spaziale e Temporale	6
2.2.3	Loss Totale di Distillation con AT	7
2.3	Born-Again Networks	7
2.4	Visualizzazione t-SNE	7
3	Architetture dei Modelli	8
3.1	Teacher: 3D ResNet-50 (slow_r50)	8
3.2	Student: MobileNet3D	9
3.3	Confronto Dimensionale	10
3.4	Accoppiamento dei Layer per l'Attention Transfer	10
4	Dataset e Protocollo Sperimentale	11
4.1	UCF-101	11
4.1.1	Caricamento e Pre-processing	11
4.2	Il Problema del Data Leakage	11
4.2.1	Evoluzione degli Split	11
4.2.2	Impatto Sulle Metriche	12
4.2.3	Implementazione dello Split Group-Aware	12
4.3	Protocollo Sperimentale Finale	12
4.4	Infrastruttura Computazionale	13
5	Implementazione della Pipeline	14
5.1	Architettura della Pipeline	14
5.2	Funzione di Loss Combinata	14
5.3	Il Bug del Block 5 ("Key 5")	15
5.4	Gestione dell'Interpolazione Spaziale	15
5.5	Warmup per la Knowledge Distillation	16
5.6	Mixed Precision Training	16

6	Risultati Sperimentali	17
6.1	Modelli di Riferimento	17
6.2	Knowledge Distillation: Risultato Principale	17
6.3	Temperature Scaling Ablation	18
6.3.1	Analisi dei Risultati	19
6.4	Attention Transfer	19
6.4.1	Analisi del Risultato Negativo	20
6.5	Born-Again Networks	20
6.5.1	Collasso Generazionale	20
6.6	Visualizzazione t-SNE dello Spazio Latente	21
6.7	Confusion Matrix	22
6.8	Riepilogo Quantitativo	24
7	Conclusioni e Lavori Futuri	25
7.1	Sintesi dei Risultati	25
7.2	Lezioni Apprese	25
7.3	Limiti del Lavoro	26
7.4	Lavori Futuri	26
7.5	Dichiarazione sull'Uso dell'IA	26

Capitolo 1

Introduzione

Il riconoscimento di azioni in sequenze video rappresenta una delle sfide più rilevanti nel campo della visione artificiale. La crescente domanda di applicazioni in tempo reale su dispositivi mobili — dalla sorveglianza intelligente alla realtà aumentata — richiede modelli che siano al contempo accurati e computazionalmente efficienti. Tuttavia, le architetture di reti neurali 3D che raggiungono le migliori prestazioni su benchmark consolidati, come la 3D ResNet-50 [3, 1], presentano decine di milioni di parametri e un costo computazionale proibitivo per il deployment su dispositivi con risorse limitate.

La **Knowledge Distillation** (KD) [4] offre un paradigma elegante per affrontare questo problema: un modello “teacher” pesante e ad alta capacità trasferisce la propria conoscenza ad un modello “student” leggero, guidandone l’apprendimento tramite distribuzioni di probabilità morbide (*soft targets*) piuttosto che le sole etichette rigide (*hard labels*). Lo student apprende così una rappresentazione più ricca rispetto a quanto otterrebbe dal solo addestramento supervisionato, pur mantenendo un’architettura compatta adatta al deployment mobile.

1.1 Obiettivi del Progetto

Questo progetto implementa una pipeline completa di Knowledge Distillation per comprimere un modello 3D ResNet-50 (*slow_r50*), pre-addestrato su Kinetics-400 [5] e sottoposto a fine-tuning su UCF-101 [9], in un modello ultra-leggero MobileNet3D [8], ottenendo una riduzione dei parametri nell’ordine di $10\times$. Gli obiettivi specifici, definiti dal Track 6 del corso, sono:

1. **Teacher Model:** valutare e consolidare un 3D ResNet-50 pre-addestrato come upper bound di accuratezza.
2. **Baseline:** addestrare un MobileNet3D da zero con sole hard labels, definendo il lower bound dell’architettura.
3. **Knowledge Transfer:** riaddestrare lo student con le distribuzioni soft del teacher.
4. **Valutazione:** confrontare Teacher, Baseline e Student distillato in termini di accuratezza, dimensione del modello e latenza di inferenza.

Oltre agli obiettivi minimi, il progetto affronta tre *Extra Objectives*:

- **Temperature Scaling Ablation:** studio dell’effetto della temperatura $T \in \{1, 5, 10, 20\}$ sulle soft distributions del teacher.

- **Attention Transfer**: estensione della KD al trasferimento delle mappe di attivazione intermedie spaziali e temporali [11].
- **Visualizzazione t-SNE**: analisi qualitativa dello spazio latente per illustrare le differenze strutturali tra teacher e student [10].

Inoltre, sono stati esplorati approcci avanzati non richiesti dal track, quali le *Born-Again Networks* [2] (self-distillation iterativa MobileNet→MobileNet).

1.2 Organizzazione della Relazione

La relazione è strutturata come segue. Il Capitolo 2 presenta i fondamenti teorici della Knowledge Distillation e dell'Attention Transfer, con particolare attenzione all'estensione al dominio video 3D. Il Capitolo 3 descrive le architetture dei modelli teacher e student. Il Capitolo 4 illustra il dataset UCF-101, il protocollo sperimentale adottato e il problema del *data leakage* affrontato durante lo sviluppo. Il Capitolo 5 dettaglia la pipeline di addestramento e le funzioni di loss implementate. Il Capitolo 6 presenta i risultati sperimentali con analisi quantitativa e qualitativa. Infine, il Capitolo 7 sintetizza i contributi e delinea i possibili sviluppi futuri.

Capitolo 2

Background Teorico

Questo capitolo presenta i fondamenti teorici su cui si basa il progetto, dalla formulazione classica della Knowledge Distillation alla sua estensione con Attention Transfer per feature video 3D.

2.1 Knowledge Distillation

La Knowledge Distillation, introdotta da Hinton et al. [4], è una tecnica di compressione dei modelli in cui un modello “teacher” ad alta capacità guida l’addestramento di un modello “student” più leggero. L’intuizione fondamentale è che le *soft predictions* del teacher — ovvero le distribuzioni di probabilità ottenute applicando un parametro di temperatura T ai logit — trasportano informazioni strutturali più ricche rispetto alle sole etichette discrete. Ad esempio, un teacher che assegna una piccola probabilità alla classe “PullUps” quando classifica “PushUps” comunica allo student una relazione semantica tra queste due azioni.

2.1.1 Formulazione Matematica

Dato un input $\mathbf{x}$, il teacher produce i logit $\mathbf{z}^T$ e lo student i logit $\mathbf{z}^S$. Le distribuzioni softmax temperate sono definite come:

$$\sigma_i(\mathbf{z}, T) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (2.1)$$

dove T è la *temperatura*. Per $T = 1$ si ottiene il softmax standard; per $T > 1$ la distribuzione diventa più uniforme, rivelando le relazioni inter-classe codificate nei logit del teacher.

La loss di Knowledge Distillation combina due componenti:

$$\mathcal{L}_{\text{KD}} = \alpha \cdot T^2 \cdot D_{\text{KL}}(\sigma(\mathbf{z}^S/T) \parallel \sigma(\mathbf{z}^T/T)) + (1 - \alpha) \cdot \mathcal{L}_{\text{CE}}(\mathbf{z}^S, y) \quad (2.2)$$

dove $\alpha \in [0, 1]$ bilancia il contributo della distillazione rispetto alla cross-entropy sulle hard labels y , e il fattore T^2 compensa la riduzione dei gradienti causata dalla temperatura.

2.1.2 Ruolo della Temperatura

La temperatura T controlla la “morbidezza” delle distribuzioni di probabilità:

- $T = 1$: le predizioni del teacher sono peaky, dominano le classi con i logit più alti; le relazioni inter-classe sono nascoste.

- $T \gg 1$: le distribuzioni si appiattiscono, rendendo visibili le correlazioni tra classi poco probabili (es. azioni simili).
- $T \rightarrow \infty$: la distribuzione converge a una uniforme, perdendo ogni informazione discriminativa.

Esiste quindi un punto ottimale che bilancia la ricchezza informativa del segnale soft con il rischio di distribuzioni troppo piatte. In questo progetto, è stato condotto uno studio ablativo sistematico con $T \in \{1, 5, 10, 20\}$ (Sezione 6.3).

2.2 Attention Transfer

L'Attention Transfer (AT), proposto da Zagoruyko e Komodakis [11], estende la KD classica al trasferimento delle *feature map intermedie*. L'idea è che la distribuzione spaziale delle attivazioni — ovvero “dove” la rete presta attenzione — trasporti informazioni discriminative complementari rispetto ai soli logit finali.

2.2.1 AT per Immagini 2D

Per la classificazione di immagini, dato un tensore di feature $F \in \mathbb{R}^{B \times C \times H \times W}$, la mappa di attenzione spaziale è definita come:

$$A(F) = \text{normalize} \left(\sum_{c=1}^C |F_c|^2 \right) \in \mathbb{R}^{B \times H \times W} \quad (2.3)$$

La loss di AT è la somma pesata degli errori MSE tra le mappe di attenzione di teacher e student su L coppie di livelli:

$$\mathcal{L}_{\text{AT}} = \beta \sum_{i=1}^L \text{MSE}(A(F_i^T), A(F_i^S)) \quad (2.4)$$

2.2.2 Estensione al Video 3D: Attenzione Spaziale e Temporale

Nel dominio video, le feature intermedie sono tensori a 5 dimensioni: $F \in \mathbb{R}^{B \times C \times T \times H \times W}$, dove T è la dimensione temporale. Un'estensione diretta dell'AT 2D al 3D — sommare sui canali e appiattire tutte le dimensioni rimanenti — è teoricamente scorretta perché mescola informazioni spaziali e temporali semanticamente diverse.

La soluzione adottata in questo progetto decompone l'attenzione in due componenti:

Mappa di Attenzione Spaziale (“dove guardare”):

$$A_{\text{spaziale}}(F) = \text{L2_norm}(\text{mean}_{c,t}(F^2)) \in \mathbb{R}^{B \times H \times W} \quad (2.5)$$

Calcola la media su canali e tempo, producendo una heatmap spaziale che riassume *dove* la rete presta attenzione per l'intera clip.

Mappa di Attenzione Temporale (“quando attivare”):

$$A_{\text{temporale}}(F) = \text{L2_norm}(\text{mean}_{c,h,w}(F^2)) \in \mathbb{R}^{B \times T} \quad (2.6)$$

Calcola la media su canali e dimensioni spaziali, producendo un profilo temporale che riassume *quando* si raggiungono i picchi di attivazione.

La loss AT combinata è:

$$\mathcal{L}_{\text{AT}} = \beta_s \sum_i \text{MSE}(A_{s,i}^T, A_{s,i}^S) + \beta_t \sum_i \text{MSE}(A_{t,i}^T, A_{t,i}^S) \quad (2.7)$$

dove β_s e β_t sono coefficienti indipendenti per le componenti spaziale e temporale.

2.2.3 Loss Totale di Distillation con AT

La funzione obiettivo complessiva combina KD e AT:

$$\mathcal{L}_{\text{totale}} = \underbrace{\alpha T^2 D_{\text{KL}} + (1 - \alpha) \mathcal{L}_{\text{CE}}}_{\text{Knowledge Distillation}} + \underbrace{\beta_s \sum_i \text{MSE}(A_{s,i}^T, A_{s,i}^S)}_{\text{AT Spaziale}} + \underbrace{\beta_t \sum_i \text{MSE}(A_{t,i}^T, A_{t,i}^S)}_{\text{AT Temporale}} \quad (2.8)$$

2.3 Born-Again Networks

Le Born-Again Networks [2] estendono la KD alla self-distillation iterativa: uno student addestrato diventa il teacher della generazione successiva, con l'obiettivo di raffinare progressivamente le rappresentazioni interne pur mantenendo la stessa architettura. In uno scenario MobileNet→MobileNet, i tensori intermedi tra teacher e student hanno la stessa dimensionalità, eliminando la necessità di interpolazione nelle mappe di attenzione. Tuttavia, come verrà discusso nella Sezione 6.5, questo approccio è soggetto a *collasso generazionale* se gli iperparametri non sono calibrati per la minore confidenza del teacher non-oracolo.

2.4 Visualizzazione t-SNE

La t-SNE (t-distributed Stochastic Neighbor Embedding) [10] è una tecnica di riduzione dimensionale non lineare che preserva la struttura locale dei dati ad alta dimensionalità. In questo progetto viene utilizzata per proiettare gli embedding pre-classificatore dei modelli teacher, baseline e student distillato in uno spazio bidimensionale, permettendo di visualizzare il grado di separazione inter-classe e la coesione intra-classe appresa da ciascun modello.

Capitolo 3

Architetture dei Modelli

Questo capitolo descrive le architetture dei modelli utilizzati nel progetto: il teacher 3D ResNet-50, lo student MobileNet3D e il meccanismo di accoppiamento dei layer per l'Attention Transfer.




Figura 3.1: Schema concettuale della Knowledge Distillation: il modello teacher pesante trasferisce la propria conoscenza allo student leggero attraverso soft targets e, opzionalmente, mappe di attenzione intermedie.

3.1 Teacher: 3D ResNet-50 (**slow_r50**)

Il modello teacher è la variante **slow_r50** di PyTorchVideo [1], un 3D ResNet-50 [3] pre-addestrato su Kinetics-400 [5]. L'architettura è composta da 6 blocchi sequenziali (indici 0-5):

Tabella 3.1: Struttura del Teacher (slow_r50). Il blocco 5 è la testa di classificazione, non uno stage di estrazione feature.

Blocco	Tipo	Output Shape	Descrizione
0	ResStage	$[B, 64, T, 56, 56]$	Conv iniziale + pool
1	ResStage	$[B, 64, T, 56, 56]$	Primo stage residuale
2	ResStage	$[B, 256, T, 28, 28]$	Secondo stage residuale
3	ResStage	$[B, 512, T, 14, 14]$	Terzo stage residuale
4	ResStage	$[B, 1024, T, 7, 7]$	Quarto stage residuale
5	ResNetBasicHead	$[B, 101]$	Global avg pool $\rightarrow$ proj

La testa di classificazione originale (pre-addestrata su 400 classi Kinetics) viene sostituita con un layer lineare a 101 uscite per UCF-101. Il pooling spaziale-temporale viene reso adattivo (`AdaptiveAvgPool3d(1,1,1)`) per supportare qualsiasi dimensione di input. Il fine-tuning utilizza SGD con learning rate 0.0007, weight decay 10^{-3} , batch size 12 e scheduler cosine annealing per 50 epoche.

3.2 Student: MobileNet3D

Lo student è un'architettura MobileNetV2 [8] adattata alle convoluzioni 3D per l'elaborazione video. L'architettura si basa su blocchi *Inverted Residual* 3D con convoluzioni depthwise separabili:

1. **Pointwise Expansion:** convoluzione $1 \times 1 \times 1$ che espande i canali di un fattore t (expansion ratio).
2. **Depthwise 3D Convolution:** convoluzione $3 \times 3 \times 3$ con `groups=hidden_dim`, che processa ciascun canale indipendentemente. Lo stride temporale è sempre 1, preservando la dimensione T .
3. **Pointwise Projection:** convoluzione $1 \times 1 \times 1$ che proietta al numero di canali di output, senza attivazione (*linear bottleneck*).

Tabella 3.2: Stage del MobileNet3D con le risoluzioni spaziali di output.

Stage	t	c	n	s	Output Shape
0	1	16	1	1	$[B, 16, T, 56, 56]$
1	6	24	2	2	$[B, 24, T, 28, 28]$
2	6	32	3	2	$[B, 32, T, 14, 14]$
3	6	64	4	2	$[B, 64, T, 7, 7]$
4	6	96	3	1	$[B, 96, T, 7, 7]$
5	6	160	3	2	$[B, 160, T, 4, 4]$
6	6	320	1	1	$[B, 320, T, 4, 4]$

dove t è l'expansion ratio, c i canali di output, n il numero di blocchi e s lo stride spaziale. Gli stage evidenziati in grassetto sono quelli utilizzati per l'Attention Transfer.

Il classificatore è composto da una convoluzione finale $1 \times 1 \times 1$ a 1280 canali, adaptive average pooling 3D, dropout (0.2) e un layer lineare a 101 classi. Il training del baseline utilizza AdamW [6] con learning rate 0.0005, weight decay 0.01 e cosine annealing per 60 epoche.

3.3 Confronto Dimensionale

Tabella 3.3: Confronto tra Teacher e Student in termini di parametri, dimensione e latenza di inferenza.

Modello	Parametri	Dimensione (MB)	Latenza (ms)
3D ResNet-50 (Teacher)	$\sim 33.4\text{M}$	~ 128	–
MobileNet3D (Student)	$\sim 2.5\text{M}$	~ 9.5	~ 1.8

Il rapporto di compressione è superiore a $13\times$ in termini di parametri e $13\times$ in dimensione del modello, rispettando ampiamente il target di $5\text{--}10\times$ richiesto dal track.

3.4 Accoppiamento dei Layer per l’Attention Transfer

L’accoppiamento corretto tra i layer del teacher e quelli dello student è cruciale per un efficace Attention Transfer. La scelta è guidata dalla similitudine semantica e dalla compatibilità delle risoluzioni spaziali:

Tabella 3.4: Accoppiamento delle feature map per l’Attention Transfer.

Coppia	Teacher	Shape Teacher	Student	Shape Student
1	Blocco 2	$[B, 256, T, 28, 28]$	Stage 2	$[B, 32, T, 14, 14]$
2	Blocco 3	$[B, 512, T, 14, 14]$	Stage 4	$[B, 96, T, 7, 7]$
3	Blocco 4	$[B, 1024, T, 7, 7]$	Stage 6	$[B, 320, T, 4, 4]$

Si noti che la dimensione temporale T è identica tra teacher e student a tutti i livelli, poiché entrambi i modelli utilizzano stride temporale pari a 1. Questo permette un trasferimento diretto dell’attenzione temporale senza interpolazione. Le differenze nelle risoluzioni spaziali (es. 28×28 vs 14×14) vengono gestite tramite interpolazione bilineare 2D, come descritto nella Sezione 5.3.

Capitolo 4

Dataset e Protocollo Sperimentale

4.1 UCF-101

Il dataset UCF-101 [9] è un benchmark consolidato per il riconoscimento di azioni, composto da 13 320 video suddivisi in 101 classi di azioni umane (sport, attività quotidiane, interazioni con oggetti). I video sono estratti da clip di YouTube e presentano sfide realistiche: variabilità di illuminazione, sfondi complessi, occlusioni parziali e variazioni intra-classe significative.

4.1.1 Caricamento e Pre-processing

Il progetto utilizza il backend `flwrlabs/ucf101` di Hugging Face, che fornisce i frame pre-estratti dei video. Il data loading pipeline opera come segue:

1. **Campionamento temporale:** per ciascun video vengono campionati $N = 24$ frame tramite campionamento segmentato uniforme. Durante il training, viene applicato un jitter temporale casuale all'interno di ciascun segmento.
2. **Trasformazioni spaziali:** i frame vengono ridimensionati a 128 pixel sul lato corto, seguiti da random crop a 112×112 (training) o center crop (evaluation). Si applica random horizontal flip con probabilità 0.5.
3. **Normalizzazione:** ogni frame viene normalizzato secondo la media e deviazione standard di Kinetics ($\mu = 0.45$, $\sigma = 0.225$ per tutti i canali).
4. **Formato:** il tensore risultante ha shape $[C, T, H, W] = [3, 24, 112, 112]$, coerente con le convenzioni PyTorchVideo.

4.2 Il Problema del Data Leakage

Una sfida critica affrontata durante lo sviluppo è stata l'identificazione e la correzione di un *data leakage* tra training e validation set. UCF-101 organizza i video per *gruppi*: video della stessa classe possono provenire dalla stessa clip sorgente, generando clip fortemente correlate.

4.2.1 Evoluzione degli Split

Il protocollo di split è passato attraverso tre fasi:

1. **Train-Test split** (fase iniziale): la validation durante il training veniva effettuata direttamente sul test set ufficiale. Questo porta a *selection bias*: il checkpoint selezionato è quello che massimizza le prestazioni sul test, rendendo le metriche troppo ottimistiche.
2. **Train-Eval-Test split senza group-aware** (prima correzione): viene creato un validation split interno dal training set, ma la separazione avviene per singolo campione, senza vincolare i gruppi video. Di conseguenza, clip della stessa sequenza sorgente possono trovarsi sia in train che in eval, producendo metriche artificialmente alte.
3. **Train-Eval-Test split group-aware** (soluzione corretta): lo split interno viene effettuato a livello di **gruppo video**. Un'espressione regolare estrae l'identificatore di gruppo (`_g\d+_`) dal video ID, garantendo che tutte le clip dello stesso video sorgente finiscano nello stesso set (train o eval). Questo elimina il leakage e produce metriche affidabili.

4.2.2 Impatto Sulle Metriche

La differenza tra i protocolli è significativa. Con lo split non-group-aware, le accuratèzze di validation raggiungevano valori sistematicamente più alti, mascherando il reale gap di generalizzazione. Con lo split group-aware, il gap tra training accuracy ($\sim 98\%$) e validation accuracy ($\sim 60\text{--}65\%$) diventa evidente, riflettendo la reale difficoltà del task.

Tutti i risultati presentati nel Capitolo 6 utilizzano esclusivamente lo split group-aware.

4.2.3 Implementazione dello Split Group-Aware

Lo split stratificato group-aware è implementato nella funzione `_stratified_group_split_indices`. Per ciascuna classe:

1. Si identificano i gruppi video unici appartenenti alla classe.
2. I gruppi vengono mescolati con un seme fisso (`seed = 42`).
3. Si assegnano interi gruppi al set di eval fino a raggiungere la `eval_ratio` target (20%), con il vincolo che almeno un campione rimanga nel train.
4. Tutti i campioni dei gruppi non selezionati finiscono nel train.

4.3 Protocollo Sperimentale Finale

Tabella 4.1: Protocollo sperimentale adottato per tutti gli esperimenti safe.

Parametro	Valore
Dataset	UCF-101 (HuggingFace backend)
Frame per clip	24
Crop size	112×112
Split	Group-aware stratificato
Eval ratio	0.2
Split seed	42
Test set	Ufficiale UCF-101

4.4 Infrastruttura Computazionale

Tutti gli esperimenti sono stati eseguiti sul cluster GPU del DMI dell'Università di Catania, gestito tramite SLURM. Le risorse principali comprendono GPU NVIDIA K80, V100 e L40S. Il progetto ha utilizzato script bash automatizzati per il lancio sequenziale di pipeline multi-stage (training $\rightarrow$ evaluation $\rightarrow$ t-SNE), con gestione dei checkpoint e fallback per la ripresa dei job interrotti.

Capitolo 5

Implementazione della Pipeline

Questo capitolo dettaglia le componenti chiave della pipeline di addestramento, con focus sulle funzioni di loss, la logica di training e il bug critico nell'Attention Transfer.

5.1 Architettura della Pipeline

La pipeline supporta quattro modalità operative, gestite dal parametro `mode` nella configurazione YAML:

- `teacher_finetune`: fine-tuning del ResNet-50 pre-addestrato su UCF-101.
- `baseline`: addestramento del MobileNet3D da zero con sola cross-entropy.
- `distillation`: KD logit-based con soft targets del teacher.
- `distillation_at`: KD + Attention Transfer spaziale/temporale.

Tutte le modalità condividono la stessa architettura di training: ottimizzatore AdamW [6], scheduler cosine annealing, mixed precision con AMP (Automatic Mixed Precision), e gradient clipping a norma 1.0.

5.2 Funzione di Loss Combinata

La loss per la modalità `distillation_at` combina tre componenti come descritto dall'Equazione 2.8. Lo pseudo-codice seguente illustra il calcolo:

Algorithm 1 Calcolo della loss combinata KD + AT**Require:** Logit student z^S , logit teacher z^T , label y **Require:** Feature teacher $\{F_i^T\}_{i=1}^L$, feature student $\{F_i^S\}_{i=1}^L$ **Require:** Temperatura T , α , β_s , β_t

```

1:  $p^S \leftarrow \text{softmax}(z^S/T)$ ,  $p^T \leftarrow \text{softmax}(z^T/T)$ 
2:  $\mathcal{L}_{\text{KD}} \leftarrow \alpha \cdot T^2 \cdot D_{\text{KL}}(p^S \| p^T) + (1 - \alpha) \cdot \text{CE}(z^S, y)$ 
3:  $\mathcal{L}_{\text{AT}} \leftarrow 0$ 
4: for  $i = 1$  to  $L$  do
5:    $A_s^T \leftarrow \text{L2\_norm}(\text{mean}_{c,t}((F_i^T)^2))$  ▷ Mappa spaziale teacher
6:    $A_s^S \leftarrow \text{L2\_norm}(\text{mean}_{c,t}((F_i^S)^2))$  ▷ Mappa spaziale student
7:    $A_s^S \leftarrow \text{interp2d}(A_s^S, \text{size} = A_s^T.\text{shape})$  ▷ Allineamento risoluzione
8:    $\mathcal{L}_{\text{AT}} \leftarrow \mathcal{L}_{\text{AT}} + \beta_s \cdot \text{MSE}(A_s^T, A_s^S)$ 
9:    $A_t^T \leftarrow \text{L2\_norm}(\text{mean}_{c,h,w}((F_i^T)^2))$  ▷ Profilo temporale teacher
10:   $A_t^S \leftarrow \text{L2\_norm}(\text{mean}_{c,h,w}((F_i^S)^2))$  ▷ Profilo temporale student
11:   $\mathcal{L}_{\text{AT}} \leftarrow \mathcal{L}_{\text{AT}} + \beta_t \cdot \text{MSE}(A_t^T, A_t^S)$ 
12: end for
13: return  $\mathcal{L}_{\text{KD}} + \mathcal{L}_{\text{AT}}$ 

```

5.3 Il Bug del Block 5 (“Key 5”)

Un bug critico ha impattato significativamente le prime iterazioni dell’Attention Transfer. In una versione iniziale del codice, i `FEATURE_BLOCKS` del teacher erano configurati come `[2, 3, 4, 5]`, dove il blocco 5 corrisponde alla **testa di classificazione** (`ResNetBasicHead`), non ad uno stage residuale. Questo blocco restituisce un tensore mono-dimensionale (`[B, 101]`) dopo il pooling e la proiezione lineare.

Le conseguenze di questo errore erano molteplici:

- Il tensore del blocco 5, non essendo una feature map volumetrica, produceva mappe di attenzione costanti (tutti i valori a 1.0 dopo la normalizzazione).
- La loss AT su questa coppia era identicamente zero, rendendo il segnale AT di fatto nullo.
- L’errore era **silenzioso**: nessuna eccezione, nessun warning, ma una convergenza dell’AT identica al training senza AT.

La correzione ha rimosso il blocco 5 dall’elenco, settando `FEATURE_BLOCKS = [2, 3, 4]`.

5.4 Gestione dell’Interpolazione Spaziale

Poiché le risoluzioni spaziali di teacher e student differiscono (Tabella 3.4), la mappa di attenzione spaziale dello student viene ridimensionata per corrispondere a quella del teacher. L’interpolazione avviene in 2D (non 3D), coerentemente con il fatto che le mappe spaziali hanno già aggregato la dimensione temporale:

1. Si fa il reshape della mappa $A^S \in \mathbb{R}^{B \times H_S \times W_S}$ a $[B, 1, H_S, W_S]$.
2. Si applica `F.interpolate` con `mode=bilinear` e `align_corners=False`.
3. Si riduce nuovamente alla dimensione della mappa teacher $[B, H_T \cdot W_T]$.

Per la dimensione temporale, non è necessaria alcuna interpolazione poiché T è identica tra teacher e student a tutti i livelli.

5.5 Warmup per la Knowledge Distillation

È stato identificato che le prime epoche di addestramento con KD beneficiano significativamente di una fase di “warmup” in cui la loss KD viene esclusa e lo student viene addestrato con sola cross-entropy. Questo permette ai parametri del modello di raggiungere una regione ragionevole dello spazio dei pesi prima di essere esposti al segnale di distillazione, evitando instabilità numeriche e convergenza prematura in minimi locali sfavorevoli. Nel progetto, un warmup di 10 epoche è stato adottato come default per tutti gli esperimenti di distillazione.

5.6 Mixed Precision Training

La pipeline utilizza AMP (*Automatic Mixed Precision*) per accelerare il training e ridurre l'occupazione di memoria GPU. Un problema specifico riscontrato è stato l'overflow in FP16 durante il calcolo delle mappe di attenzione: l'operazione F^2 su feature map con valori grandi genera overflow nel range di float16. La soluzione adottata è il casting esplicito a float32 prima dell'operazione di potenza:

```
# Cast esplicito per stabilità numerica con AMP
f = f.float() # float32
return (f * f).mean(dim=...)
```

Questo garantisce stabilità numerica senza disabilitare AMP per l'intero training.

Capitolo 6

Risultati Sperimentali

Questo capitolo presenta i risultati ottenuti con lo split group-aware su UCF-101. Tutti i valori di accuratezza riportati come “Test” si riferiscono al test set ufficiale; quelli come “Val” si riferiscono alla porzione di validation estratta dal training set con split group-aware.

6.1 Modelli di Riferimento

Tabella 6.1: Performance dei modelli di riferimento sul test set ufficiale.

Modello	Val Top-1	Test Top-1	Test Top-5	Size (MB)
Teacher (3D ResNet-50)	92.36%	88.82%	98.18%	~128
Baseline (MobileNet3D)	59.18%	59.48%	82.77%	~9.5

Il **gap** tra teacher e baseline è di circa **29.3 punti percentuali** in Top-1, confermando l’esistenza di un significativo *capacity gap* tra le due architetture. Questo gap è la motivazione fondamentale per la Knowledge Distillation: trasferire allo student parte della conoscenza strutturale del teacher che non emerge dal solo addestramento con hard labels.

6.2 Knowledge Distillation: Risultato Principale

L’esperimento principale di KD utilizza temperatura $T = 8$ e $\alpha = 0.7$:

Tabella 6.2: Confronto Baseline vs Knowledge Distillation ($T = 8$, $\alpha = 0.7$).

Modello	Val Top-1	Test Top-1	Test Top-5	Δ vs Baseline
Baseline	59.18%	59.48%	82.77%	—
KD ($T = 8$)	64.57%	64.31%	87.68%	+4.83%

La Knowledge Distillation produce un miglioramento significativo di **+4.83 punti percentuali** in Test Top-1 e +4.91% in Top-5, senza alcuna modifica all’architettura del modello. Lo student distillato raggiunge il 64.31% mantenendo la stessa dimensione di 9.5 MB e la latenza di ~1.8 ms.




Figura 6.1: Curve di accuracy per il training di KD con $T = 8$, $\alpha = 0.7$. Si noti il gap tipico tra training accuracy ($\sim 98\%$) e validation accuracy ($\sim 64\%$), indicativo della difficoltà del task con split group-aware.




Figura 6.2: Andamento della loss durante il training di KD ($T = 8$).

6.3 Temperature Scaling Ablation

È stato condotto uno studio ablativo sistematico dell'effetto della temperatura sulle soft distributions del teacher:

Tabella 6.3: Ablazione sulla temperatura con $\alpha = 0.7$ fisso.

T	Best Val	Best Epoch	Train Acc	Test Top-1	Test Top-5	Δ vs BL
1	62.75%	60	98.44%	62.91%	85.59%	+3.43%
5	63.12%	57	95.87%	62.07%	87.02%	+2.59%
8	64.57%	56	97.59%	64.31%	87.68%	+4.83%
10	64.85%	60	98.28%	64.47%	87.44%	+4.99%
20	65.18%	59	99.05%	65.85%	87.81%	+ 6.37%

6.3.1 Analisi dei Risultati

L'andamento mostra un chiaro trend crescente con la temperatura. La configurazione con $T = 20$ raggiunge la migliore Test Top-1 accuracy (**65.85%**), con un miglioramento di **+6.37 punti percentuali** rispetto al baseline.

Questo risultato suggerisce che, per il gap di capacità significativo tra 3D ResNet-50 e MobileNet3D, temperature più alte che producono distribuzioni più uniformi risultano più efficaci. Con temperature basse ($T = 1$), le predizioni del teacher sono troppo “peaky” e lo student fatica a replicare la distribuzione inter-classe. Temperature alte ($T = 20$) “smussano” la distribuzione del teacher, esponendo relazioni tra classi che uno student limitato può meglio approssimare.




Figura 6.3: Delta di accuratezza (test) rispetto al baseline per ciascuna temperatura. Trend crescente con la temperatura, con picco a $T = 20$.

6.4 Attention Transfer

L'Attention Transfer estende la KD con il trasferimento delle mappe di attenzione intermedie. Sono state testate due configurazioni:

Tabella 6.4: Risultati dell'Attention Transfer (split group-aware). Le colonne β_s e β_t indicano i pesi delle componenti spaziale e temporale.

Config	β_s	β_t	Val Top-1	Train Acc
KD ($T = 8$, no AT)	0	0	64.57%	97.59%
AT Simmetrico	0.05	0.05	58.25%	96.27%
AT Temporal-Only	0	0.10	59.04%	95.87%

6.4.1 Analisi del Risultato Negativo

L'Attention Transfer non ha migliorato le prestazioni rispetto alla sola KD. Anzi, entrambe le configurazioni producono una **regressione** di 5–6 punti percentuali. Diverse ipotesi spiegano questo risultato:

1. **Capacity gap spaziale:** il teacher utilizza convoluzioni standard 3D con $C \gg 1$ canali che interagiscono liberamente, producendo mappe di attenzione spaziale ricche e dettagliate. Il MobileNet3D utilizza convoluzioni depthwise separabili, dove ciascun canale è processato indipendentemente; questo limita intrinsecamente la capacità dello student di riprodurre le mappe spaziali del teacher.
2. **Regularizzazione eccessiva:** il segnale AT spaziale può agire come un vincolo troppo restrittivo sulle feature intermedie, impedendo allo student di trovare soluzioni alternative compensatorie adatte alla sua architettura più limitata.
3. **Dominanza del componente temporale:** l'AT puramente temporale ($\beta_s = 0$, $\beta_t = 0.1$) performa leggermente meglio del simmetrico, suggerendo che il componente spaziale è il principale responsabile della regressione.

Questo risultato è coerente con la letteratura: il paper originale di Zagoruyko e Komodakis [11] lavora con architetture della stessa famiglia (ResNet teacher $\rightarrow$ ResNet student), dove la similarità strutturale rende le mappe di attenzione più trasferibili.

6.5 Born-Again Networks

Le Born-Again Networks tentano di migliorare lo student tramite self-distillation iterativa. Il migliore KD student ($T = 8$, $\alpha = 0.7$) diventa il teacher della Generazione 1, che a sua volta diventa teacher della Generazione 2, e così via.

Tabella 6.5: Risultati Born-Again Networks (3 generazioni successive). Si noti il collasso progressivo delle prestazioni.

Generazione	Teacher	Val Top-1	Test Top-1	Δ vs Gen0
Gen 0 (KD $T = 8$)	ResNet-50	64.57%	64.31%	—
Gen 1	Gen 0	60.78%	60.98%	−3.33%
Gen 2	Gen 1	61.20%	60.43%	−3.88%
Gen 3	Gen 2	59.98%	59.21%	−5.10%

6.5.1 Collasso Generazionale

Il risultato mostra un chiaro **collasso generazionale**: ogni iterazione successiva produce prestazioni inferiori, anziché il miglioramento atteso dalla teoria [2]. Il collasso è progressivo: Gen 3 scende sotto il livello del baseline originale (59.21% vs 59.48%).

Le cause identificate:

1. **Temperature non calibrata:** la temperatura $T = 2.5$ usata per la self-distillation era stata scelta per un teacher oracolo (ResNet-50 a $\sim 89\%$). Un MobileNet3D a $\sim 64\%$ produce distribuzioni soft meno informative, e una temperatura troppo alta le rende ancora più piatte, diluendo il segnale utile.

2. **Assenza di oracolo:** le Born-Again Networks presuppongono che il teacher della generazione k sia almeno competente quanto quello della generazione $k - 1$. Quando il teacher iniziale è già un modello limitato, il degrado della qualità del segnale si accumula.
3. **Overfitting sugli artefatti:** il teacher non-oracolo commette errori sistematici che vengono amplificati e rinforzati nelle generazioni successive.

6.6 Visualizzazione t-SNE dello Spazio Latente

La t-SNE è stata applicata alle embedding pre-classificatore per analizzare qualitativamente le rappresentazioni apprese. Per ciascuna visualizzazione, vengono selezionate 10 classi casuali e proiettate in 2D.



Figura 6.4: t-SNE a tre colonne: Teacher (ResNet-50), Baseline (MobileNet3D), e Student distillato (KD $T = 8$). Il teacher mostra cluster compatti e ben separati; il baseline presenta sovrapposizione; lo student distillato mostra una struttura intermedia migliorata.




Figura 6.5: t-SNE per i modelli con Attention Transfer: il pattern di clustering è simile a quello del baseline, confermando che l'AT non ha prodotto miglioramenti strutturali nelle rappresentazioni.




Figura 6.6: t-SNE delle Born-Again Networks: la struttura non migliora nelle generazioni successive, coerentemente con il collasso osservato nelle metriche quantitative.

6.7 Confusion Matrix

Le confusion matrix normalizzate evidenziano le classi più confuse. Per leggibilità, vengono mostrate le Top-25 classi più problematiche.




Figura 6.7: Confusion matrix Top-25 del Teacher: errori concentrati su classi semanticamente ambigue.




Figura 6.8: Confusion matrix Top-25 del Baseline: pattern di confusione più diffusi, in particolare tra azioni sportive visivamente simili.




Figura 6.9: Confusion matrix Top-25 del migliore Student distillato (KD $T = 20$): pattern di errore ridotto rispetto al baseline, evidenziando un trasferimento effettivo della conoscenza discriminativa del teacher.

6.8 Riepilogo Quantitativo

Tabella 6.6: Riepilogo completo di tutti gli esperimenti con split group-aware.

Esperimento	Val Top-1	Test Top-1	Test Top-5	Δ
Teacher (ResNet-50)	92.36%	88.82%	98.18%	upper bound
Baseline (MobileNet3D)	59.18%	59.48%	82.77%	reference
KD $T = 1$, $\alpha = 0.7$	62.75%	62.91%	85.59%	+3.43%
KD $T = 5$, $\alpha = 0.7$	63.12%	62.07%	87.02%	+2.59%
KD $T = 8$, $\alpha = 0.7$	64.57%	64.31%	87.68%	+4.83%
KD $T = 10$, $\alpha = 0.7$	64.85%	64.47%	87.44%	+4.99%
KD $T = 20$, $\alpha = 0.7$	65.18%	65.85%	87.81%	+6.37%
AT Simmetrico	58.25%	—	—	−5.93% val
AT Temporal-Only	59.04%	—	—	−5.14% val
Born-Again Gen 1	60.78%	60.98%	—	−3.33%
Born-Again Gen 2	61.20%	60.43%	—	−3.88%
Born-Again Gen 3	59.98%	59.21%	—	−5.10%

Capitolo 7

Conclusioni e Lavori Futuri

7.1 Sintesi dei Risultati

Questo progetto ha implementato e valutato una pipeline completa di Knowledge Distillation per la compressione di un modello 3D ResNet-50 (33.4M parametri) in un MobileNet3D (2.5M parametri) per il riconoscimento di azioni su UCF-101. I risultati principali sono:

1. **KD Logit-based**: la Knowledge Distillation produce un miglioramento consistente rispetto al baseline. La configurazione migliore ($T = 20$, $\alpha = 0.7$) raggiunge il **65.85%** di Test Top-1 accuracy, con un guadagno di **+6.37 punti percentuali** rispetto al baseline (59.48%), colmando circa il **22%** del gap tra student e teacher.
2. **Temperature Scaling**: lo studio ablativo rivela un trend crescente con la temperatura nel range $[1, 20]$, suggerendo che per coppie teacher-student con capacity gap significativo, temperature alte che “smussano” le distribuzioni del teacher facilitano il trasferimento della conoscenza.
3. **Attention Transfer**: l’estensione con AT spaziale e temporale non ha prodotto miglioramenti, anzi una regressione di 5–6 punti. Questo risultato evidenzia i limiti del trasferimento delle mappe di attenzione tra architetture strutturalmente eterogenee (convoluzioni standard vs depthwise separabili).
4. **Born-Again Networks**: la self-distillation iterativa MobileNet→MobileNet produce un collasso generazionale, scendendo sotto il baseline alla terza generazione. Il risultato è attribuibile alla temperatura non calibrata e all’assenza di un teacher oracolo.
5. **Compressione**: il modello finale mantiene una dimensione di **9.5 MB** (vs ~ 128 MB del teacher), una latenza di ~ 1.8 ms, e un rapporto di compressione superiore a **13×**.

7.2 Lezioni Apprese

Il percorso di sviluppo ha evidenziato alcune lezioni significative:

- **Data leakage silenzioso**: il leakage tra train e validation dovuto ai gruppi video di UCF-101 è un problema insidioso che produce metriche artificialmente alte senza generare errori espliciti. Lo split group-aware è essenziale per qualsiasi valutazione affidabile su questo dataset.

- **Bug silenti nelle pipeline complesse:** il bug del Block 5 nell'Attention Transfer — che produceva mappe costanti senza alcun warning — dimostra l'importanza della validazione delle feature intermedie tramite ispezione manuale, non solo della loss finale.
- **Stabilità numerica con AMP:** il mixed precision training richiede attenzione esplicita quando si calcolano potenze di feature map, poiché l'overflow in float16 può propagarsi silenziosamente come NaN.
- **Warmup per KD:** le prime epoche di distillazione beneficiano di una fase di warmup con sola cross-entropy, permettendo ai pesi dello student di raggiungere una regione ragionevole prima di essere esposti al segnale soft del teacher.

7.3 Limiti del Lavoro

- L'ablazione sulla temperatura è stata condotta con $\alpha = 0.7$ fisso; un'analisi congiunta $T \times \alpha$ potrebbe rivelare configurazioni ottimali diverse.
- L'AT è stato testato con un solo set di (β_s, β_t) ; uno sweep più ampio e un'esplorazione di tecniche di accoppiamento alternative (FitNets [7], proiezione lineare) potrebbero produrre risultati diversi.
- Le Born-Again Networks sono state testate con temperatura fissa; un decay della temperatura attraverso le generazioni potrebbe mitigare il collasso.
- Il progetto utilizza un singolo split seed; la riproducibilità dei risultati andrebbe verificata su split multipli.

7.4 Lavori Futuri

1. **Progressive distillation:** utilizzare temperature decrescenti nelle Born-Again Networks per mantenere la qualità del segnale attraverso le generazioni.
2. **Feature projection AT:** inserire layer lineari trainabili tra le feature del teacher e dello student per ridurre il mismatch architetturale nell'AT.
3. **Distillazione multi-teacher:** combinare i segnali di teacher con architetture diverse per produrre soft targets più robusti.
4. **Deployment reale:** integrare il modello compresso in un'applicazione mobile con benchmark di latenza su dispositivi edge (Raspberry Pi, smartphone Android).
5. **Dataset più complessi:** estendere la valutazione a Kinetics-400 o HMDB-51 per verificare la generalizzabilità dei risultati.

7.5 Dichiarazione sull'Uso dell'IA

Coerentemente con la policy del corso, si dichiara che durante lo sviluppo del progetto sono stati utilizzati strumenti di intelligenza artificiale generativa (GitHub Copilot, Claude) come supporto per: la scrittura di codice boilerplate, il debugging di errori, la consultazione della documentazione di PyTorch e PyTorchVideo, e l'automazione della pipeline di testing. Le

decisioni architettoniche, la strategia sperimentale e l'interpretazione dei risultati sono state interamente formulate dall'autore.

Bibliografia

- [1] Christoph Feichtenhofer, Haoqi Fan, Jitendra Malik, and Kaiming He. Slowfast networks for video recognition. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 6202–6211, 2019.
- [2] Tommaso Furlanello, Zachary C. Lipton, Michael Tschannen, Laurent Itti, and Anima Anandkumar. Born again neural networks. In *International Conference on Machine Learning (ICML)*, pages 1607–1616, 2018.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [4] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. In *NeurIPS Workshop on Deep Learning*, 2015.
- [5] Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, Mustafa Suleyman, and Andrew Zisserman. The kinetics human action video dataset. In *arXiv preprint arXiv:1705.06950*, 2017.
- [6] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [7] Adriana Romero, Nicolas Ballas, Samira Ebrahimi Kahou, Antoine Chassang, Carlo Gatta, and Yoshua Bengio. Fitnets: Hints for thin deep nets. *arXiv preprint arXiv:1412.6550*, 2015.
- [8] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4510–4520, 2018.
- [9] Khurram Soomro, Amir Roshan Zamir, and Mubarak Shah. Ucf101: A dataset of 101 human actions classes from videos in the wild. *arXiv preprint arXiv:1212.0402*, 2012.
- [10] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [11] Sergey Zagoruyko and Nikos Komodakis. Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer. In *International Conference on Learning Representations (ICLR)*, 2017.